


PROYECTO ETL: PIPELINE DE DATOS MEETUP

Pipeline ETL - Datos de Meetup

Flujo de datos de extremo a extremo



PROYECTO ETL: PIPELINE DE DATOS MEETUP

- Objetivo: Automatizar la ingestión, transformación y almacenamiento de datos
- Tecnologías: Apache Airflow, Snowflake, Docker Compose y Slack
- Características clave: DAGs modulares, variables centralizadas y logging detallado

VISIÓN GENERAL DEL PIPELINE

- Fuentes de datos: Archivos CSV (categorías, ciudades, eventos, etc.)
- Staging: Carga de datos crudos en tablas staging de Snowflake
- Transformación: Limpieza y upsert de datos en tablas finales
- Exportación: Guardado de datos procesados en S3

DAGS DE AIRFLOW

- `load_csv_to_stage.py`: Carga de CSVs hacia staging en Snowflake
- `stage_to_stg_tables.py`: Transformación de datos staging
- `upsert_tablas.py`: Upsert de datos en tablas finales
- `export_to_s3.py`: Exportación de datos hacia S3

ESTRUCTURA DEL PROYECTO

- airflow/dags: Contiene todos los scripts DAG
- airflow/data: Almacena archivos CSV de entrada
- airflow/logs: Logs de ejecución de los DAGs
- postgres/airflow_init.sql: Script de inicialización de base de datos

OBJETIVO DE LA SIMULACIÓN DEL PROYECTO

- El proyecto simula el procesamiento de lotes de nuevos datos desde archivos fuente.
- Los nuevos datos son ingeridos, procesados y almacenados en la base de datos.
- Las tablas finales siempre contienen la versión más reciente de los datos para análisis.
- El área de preparación conserva versiones anteriores de los archivos recibidos para su consulta.

CONCLUSIÓN

- El pipeline ETL automatiza eficientemente el procesamiento de datos
- El diseño modular garantiza escalabilidad y mantenibilidad
- El logging y las notificaciones mejoran el monitoreo
- Listo para futuras integraciones y tareas de datos